Криптонит: Тембр

Решение команды AI Amigos для задачи speaker retrieval

Что требовалось

- Для каждой из 134 697 тестовых записей найти 10 самых похожих аудио.
- Работать в open-set режиме: test speakers не размечены.
- Максимизировать Precision@10 на leaderboard.

Итоговый лучший результат P@10:

0.7439

Финальный best-known pipeline:

- CAM++ stage3 (55%) + ERes2Net stage3 (45%)
- TTA10* на обеих моделях
- k-reciprocal rerank: k1=70, k2=6, λ=0.1

* TTA10 -TTA (Test-Time Augmentation) - это извлечение и усреднение эмбеддингов по 10 временным кропам одной аудиозаписи отдельно для CAM++ и отдельно для ERes2Net перед их ансамблированием.

Постановка задачи и данные

Почему здесь retrieval естественнее, чем кластеризация или классификация на тесте

Постановка

- На тесте нет speaker_id, нужно вернуть top-10 соседей для каждой записи.
- Это retrieval по эмбеддингам, а не closed-set классификация.
- На инференсе используется nearest-neighbor search по косинусной близости.

Данные

- Train: 673 277 FLAC, 16 kHz, 11 053 диктора.
- Test public: 134 697 FLAC без меток.
- Ключевая сложность: шумы, реверберация, far-field и кодеки.

Инференс-постановка

Ключевой инсайт

Проблема была не только в модели, а в переносе на шумный test domain

Конфигурация	Val P@10	Public P@10	Вывод
Baseline ONNX	0.8941	—	Стартовая точка
ECAPA v1, синтетические аугм.	0.9458	0.2699	Провал из-за domain shift
ECAPA v2, MUSAN + RIR	0.9465	0.3717	Реальные аугментации помогают
CAM++ zero-shot	—	0.4560	Сильный предобученный encoder

Вывод: высокая локальная валидация на “чистом” сплите сама по себе не гарантирует лидерборд. Основные источники роста - реальные шумы MUSAN/RIR, более сильные speaker-модели и правильный retrieval post-processing.

Эволюция качества

Как шаг за шагом улучшался public leaderboard

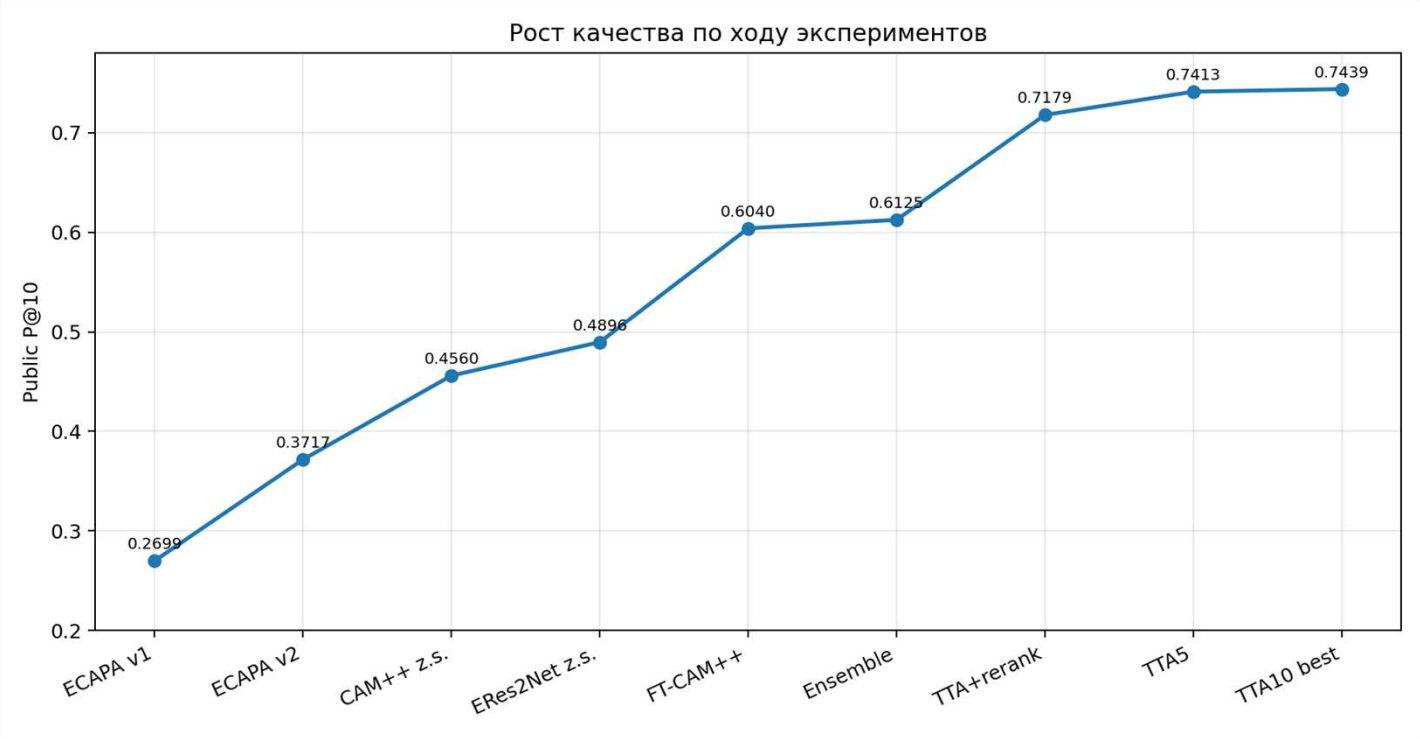

Ключевые этапы

- FT-CAM++: 0.6040
- Ансамбль FT-CAM++ + ERes2Net: 0.6125
- TTA + rerank: 0.7179
- Stage3 + TTA5: 0.7413
- TTA10 + alpha-sweep: 0.7439

Финальный лучший пайплайн

Конфигурация, которую фиксируем как best-known solution

Параметры финальной конфигурации

- TTA10 на обеих моделях: оптимум, TTA20 уже не помог.
- Оптимальный blend: CAM++ 55%, ERes2Net 45%.
- Оптимальный rerank: k1=70, k2=6, λ=0.1.
- Итоговый public P@10 = 0.7439.

Что реально дало прирост

А что оказалось тупиковыми ветками

Сработало

- Реальные аугментации MUSAN + RIR.
- Fine-tune CAM++ и ERes2Net на train-данных конкурса.
- TTA по временным кропам.
- K-reciprocal reranking как основной постпроцессинг.
- Небольшой alpha sweep вокруг лучшей пары.

Не сработало

- ECAPA как 3-я модель в ансамбле.
- Verifier как самостоятельный reranker.
- Локальные top-20 эвристики.
- ERes2NetV2 как прямая замена ERes2Net.
- WavLM stage2 в обычном ансамбле.

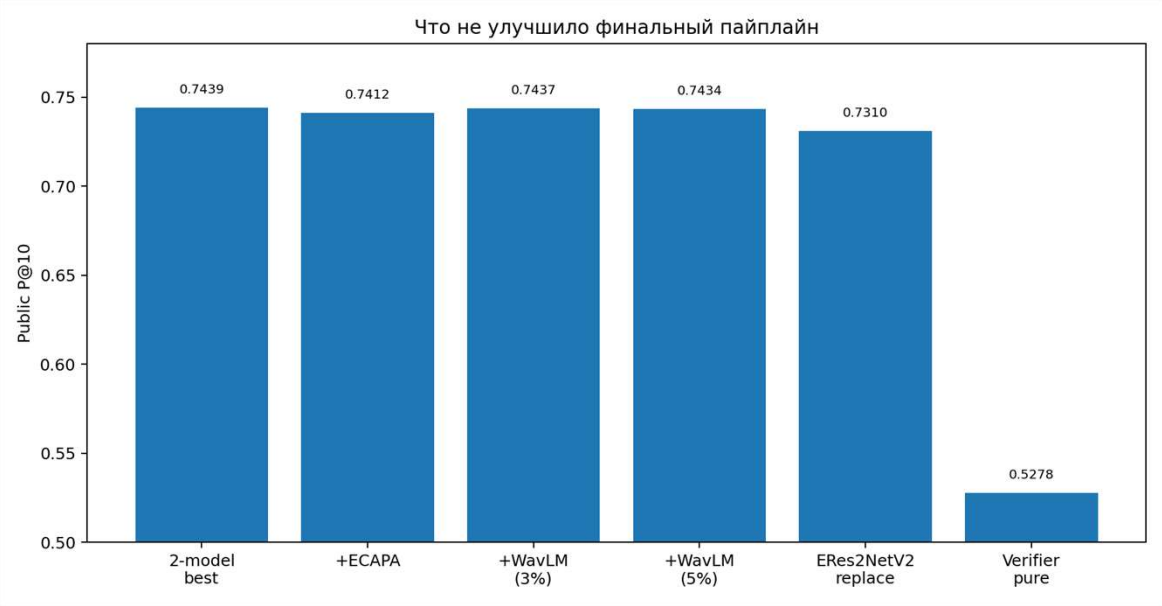

Ключевые результаты по веткам

Сжатая сводка для защиты

Этап	Public P@10	Комментарий
CAM++ zero-shot	0.4560	Первый сильный предобученный speaker encoder
ERes2Net zero-shot	0.4896	Лучший zero-shot результат
FT-CAM++ solo	0.6040	Главный скачок от fine-tune
FT-CAM++ + ERes2Net	0.6125	Ансамбль даёт комплементарный сигнал
TTA + rerank	0.7179	Крупнейший буст после улучшения эмбеддингов
Stage3 + TTA10 + alpha=0.55	0.7439	Текущий лучший результат

Главный практический вывод: на этой задаче решают не только хорошие эмбеддинги, но и корректный retrieval post-processing на широком пуле соседей.

Финальный статус и выводы

Что сдаём и как позиционируем решение

Что сдаём

- Inference pipeline - воспроизводимый контейнер, работающий без интернета (Шаг 1: сборка + загрузка весов; Шаг 2: офлайн-инференс)
- submission_best.csv с top-10 соседями для всех test-записей.
- Инструкция запуска, ссылка на веса на HuggingFace: s0ft44/kryptonit-tembr-weights
- Отчёт и презентация - описание экспериментов, результаты и выводы

Итоговый вывод

- Best-known solution: CAM++ stage3 + ERes2Net stage3 + TTA10 + rerank.
- Текущий public результат: 0.7439.
- Дальнейший существенный рост потребует нового encoder-сигнала, а не микротюнинга текущего пайплайна.

Спасибо!